Codeit AI Sprint 15기 · 초급 프로젝트 (개인)

경구약제 이미지 객체 검출

사진 한 장에서 최대 4개 알약의 종류(56종)와 위치를 찾는다

기간	2026.10.27 – 2026.11.06
작성	이다교 (github.com/lee-da-gyo)
저장소	github.com/lee-da-gyo/ai-project-01-pill-detection
환경	Python 3.14 · PyTorch 2.11 · Ultralytics 8.4 · RTX 3060 12GB

요약

학습 이미지는 232장, 약은 56종이며 절반 이상이 10개 미만의 박스만 가진 롱테일 데이터다. 같은 알약 조합을 각도만 바꿔 최대 세 번(조합당 1~3장) 찍은 구조라, 이미지 단위로 나누면 검증 점수가 부풀려진다. 이 프로젝트는 **모델을 바꾸기 전에 "정직하게 재는 법"을 먼저 만들었다.**

15건	0건	0.950	0.413
라벨 오류 발견·수정 (14장) (배경 분할 감사 10 + 오류 분석 뒤 감사 5)	같은 조합의 검증 누수 (조합 단위 5-Fold)	최종 후보의 5-Fold OOF mAP@[.75:.95] (대회 표기 기반 내부 대리지표, 37종 조건부 진단값, 단일 모델 0.938)	주력 제출의 Kaggle public 점수 (내부 대리지표보다 크게 낮다, 7.2절)

- **핵심 발견** – 오류는 위치가 아니라 **학습 때 본 적 없는 약의 이름**에서 나온다 (OOF에서 학습 가능 37종의 AP50-95 중앙값 0.992, 처음 보는 19종은 사실상 0). 처음 보는 약의 24%는 신뢰도 0.9 이상으로 다른 약 이름을 받아, 신뢰도만으로는 걸러지지 않는다 (8.5절).
- **현재 최종 후보** – YOLO11s + YOLO11m을 232장 전체로 학습하고 WBF(2:1, IoU 0.6)로 합친다. 설정은 5-Fold 예측을 대리지표로 평가해 골랐고, fold를 하나씩 보류하는 근사 메타 검증 5회에서 모두 2:1 가중치가 뽑혔다.
- **기각한 시도** – 고해상도, YOLO26, Copy-Paste 합성, 2단계(검출+분류기), CLAHE 전처리, 학습률 변경, TTA. 각 시도의 기각 근거를 수치로 남겼다.
- **한계** – 한 fold에만 있는 희귀 19종은 검증 때마다 학습에 없어, 이 데이터로는 그 약들의 실제 성능을 잴 수 없다.

목차

1. 문제 정의
2. 데이터 분석 (EDA)
3. 데이터 정제
4. 검증 전략
5. 모델과 실험 설계
6. 실험 결과와 의사결정
7. 최종 후보 모델과 제출
8. 결과 분석
9. 재현성과 코드 품질
10. 업무 수행 과정
11. 비즈니스 시사점과 한계
12. 회고와 향후 과제

1. 문제 정의

1.1 배경

헬스케어 스타트업 **헬스잇(Health Eat)**은 사용자가 복용 중인 약을 촬영하면 어떤 약인지 자동으로 알려 주는 기능을 만들고자 한다. 약을 정확히 알아보면 **함께 먹으면 안 되는 약 안내**, 복약 기록 같은 서비스로 확장할 수 있다. 이 프로젝트는 그 첫 단계인 인식 모델을 만든다.

1.2 과제

항목	내용
과제 유형	객체 검출 (Object Detection): 알약마다 약 종류(클래스)와 바운딩 박스를 함께 예측
입력	단색 배경 위에 알약 3~4개가 놓인 사진 (976 × 1280)
데이터	학습 232장 (박스 771개, 56종) · 테스트 842장 (정답 비공개, Kaggle로 채점)
제약	AI Hub 경구약제 이미지 데이터[12] 중 `TL_2_조합.zip`과 그 원천 데이터 `TS_2_조합`만 사용 금지 (그 밖의 AI Hub 데이터는 허용, 이 프로젝트에서는 쓰지 않았다) · 테스트에 학습에 없는 클래스 존재 (대회 안내) · Kaggle 하루 10회 제출

1.3 평가 지표

대회 페이지의 평가 지표 표기는 mAP@[0.75:0.95]다. 이 보고서는 이 표기를 COCO 관례(0.05 간격 5개, `configs/evaluation.yaml`)로 해석한 **내부 대리지표**(이하 대리지표)를 계산한다. 주최 측 평가 코드 또는 공식 점수와의 동등성은 확인하지 못했다. 약 이름과 함께 **박스를 얼마나 정확히 그렸는지**를 더 엄격하게 본다. 실험 대부분은 대회 페이지의 표기를 확인하기 전에 COCO 표준 **mAP@[.5:.95]**(이하 mAP50-95)로 비교했으므로, 이 보고서의 실험 표는 mAP50-95를 쓴다. 대회 페이지를 프로젝트 후반에야 확인한 것은 실수다. 확인한 뒤 학습 없이 저장된 예측으로 최종 결정들을 대리지표로 다시 평가했고, 그 결과 WBF의 IoU 하나가 바뀌었다(6.6절). 그 차이(0.0007)는 작아서 주최 측 해석이 다르면 선택이 달라질 수 있다. 검증에는 pycocotools[3]로 직접 계산한 COCO mAP[2]를 쓴다. 베이스라인에서 Ultralytics 내장 평가(0.834)와 직접 구현(0.835)이 일치함을 확인했고, 덕분에 앙상블·2단계 모델처럼 Ultralytics 밖에서 만든 예측도 같은 기준으로 비교할 수 있었다.

제출 파일은 대회 안내의 8개 열(annotation_id, image_id, category_id, bbox_x, bbox_y, bbox_w, bbox_h, score)과 일치함을 확인했다.

2. 데이터 분석 (EDA)

EDA의 목적은 그래프를 많이 그리는 것이 아니라 **데이터의 특성을 설계 결정으로 바꾸는 것**이다. 발견 6가지를 각각 하나의 결정으로 연결했다.

발견	근거	결정
데이터가 매우 적다	학습 232장으로 테스트 842장을 예측	COCO 사전학습 YOLO 파인튜닝
심한 클래스 불균형	최대 157개 vs 최소 3개 (약 50배). 56종 중 29종이 박스 10개 미만	클래스별 AP 추적, 희귀 약 보강 시도 (Copy-Paste)
사실상 1장짜리 클래스	17종은 같은 장면을 각도만 바꾼 3장이 전부	증강으로 맥락 다양화, 성능 측정의 한계로 명시
같은 조합을 여러 각도로	114개 조합을 최대 세 각도(70° / 75° / 90°)로 촬영. 실제 보유 수는 3장 40조합, 2장 38조합, 1장 36조합	2~3장인 78개 조합은 거의 같은 장면이 반복된다 → 이미지 단위 분할은 누수 → **조합 단위 분할** (4장)
고정된 배치 위치	박스 중심이 몇 개 슬롯에 몰려 있음	이동·모자이크 증강으로 위치 편향 방지
Train/Test 분포 차이	Test가 약간 어둡고(밝기 131.5 → 125.9) 대비가 큼(23.6 → 26.5)	밝기·대비 증강, CLAHE 전처리 비교 (6.5절)

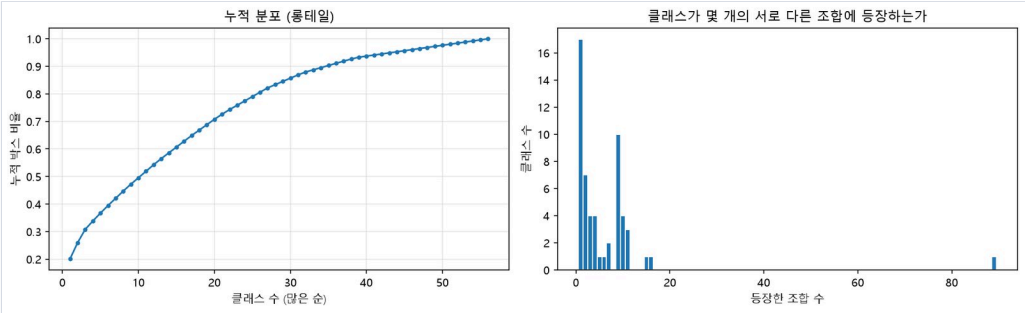


그림 2-1. 왼쪽: 상위 10종이 박스의 49.5%를 차지하는 롱테일. 오른쪽: 17종은 단 하나의 조합에만 등장한다



그림 2-2. 같은 조합을 각도만 바꿔 촬영 → 이미지 단위로 나누면 누수

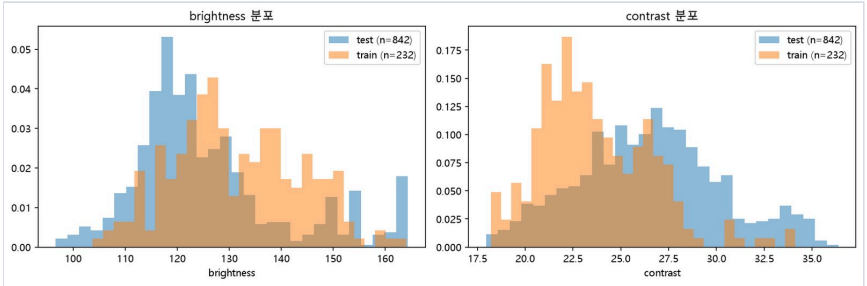


그림 2-3. Train vs Test 밝기·대비 분포 (244×320 썸네일의 RGB 평균·표준편차)

3. 데이터 정제

라벨이 틀렸는지 확인하려면 **라벨과 독립적인 기준**이 필요하다. 배경이 단색에 가깝다는 EDA 결과를 이용해, 배경 차분(Lab 색 거리 + Otsu 이진화)으로 알약 영역을 분할하고 라벨과 대조했다. 또 하나의 기준은 파일명이다. 파일명에는 조합의 약 코드가 들어 있고, 232장 중 224장에서 라벨의 약 목록과 정확히 일치했다 (나머지 8장은 모두 "라벨 하나가 빠진" 경우).

오류 유형	탐지 규칙	수정	건수
범위 밖 박스	좌표가 이미지 밖 (x = 6567)	숫자 하나를 뺀 후보 중 라벨 없는 알약과 가장 잘 맞는 값 → x = 567	1
엉뚱한 위치	박스 안이 배경 + 겹치지 않는 같은 크기의 라벨 없는 알약 존재	그 알약 위치로 이동	1
누락 박스	파일명의 약 코드 중 라벨 없는 것 1개 + 라벨 없는 알약 1개	해당 코드로 박스 추가 (같은 조합 다른 각도 사진과 생김새 대조)	8
다른 약끼리 같은 좌표 *	한 이미지에서 다른 약 박스 쌍의 IoU ≥ 0.9 (후보만 자동 탐지)	다른 각도 사진으로 확인한 틀린 라벨을 라벨 없는 알약으로 이동	3
라벨 교환 *	OOF 예측이 정답과 신뢰도 0.9 이상으로 다르게 답함 (모델 보조 사후 감사)	다른 각도 사진으로 확인한 두 박스의 약 코드 교환	1장 (2박스)

표 3-1. * 오류 분석(8장) 뒤에 추가한 감사. 앞의 네 유형은 모델 예측을 쓰지 않는 데이터 내부 감사이고, 라벨 교환은 모델 예측으로 후보를 만든 비독립 감사다. 후보는 자동으로 고치지 않고 사람이 확인한 결정(`configs/label_review.csv`: 검수자 · 검수일 · 검수 때 본 좌표 포함)만 적용했다. 실제로 겹쳐 놓인 알약이면 고치지 않는 결정(keep_overlap)으로 남기고, 무결성 검사는 "결정이 없는 D 후보 0"을 확인한다 (keep_overlap도 두 박스가 검수 때 본 좌표 그대로일 때만 겹침을 허용). 출처: reports/label_fixes.csv, label_audit_candidates.csv

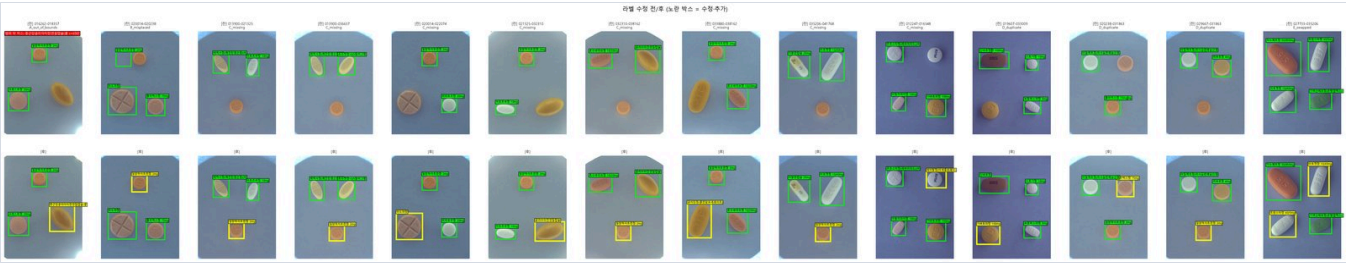


그림 3-1. 라벨 수정 전후 (위: 원본, 아래: 정제. 노란 박스 = 수정·추가)

실패에서 배운 점 – 처음 만든 "빈 박스 이동" 규칙은 6건을 고쳤지만 그중 **5건이 오탐**이었다. 반투명 캡슐과 파란 알약은 분할이 잘 되지 않아 박스가 비어 보였던 것이다. "원래 박스와 겹치지 않고 크기가 비슷한 알약이 따로 있다"는 조건을 더해 진짜 오류 1건만 남겼다. 자동 규칙의 결과 10건은 모두 이미지로 육안 검수했다 (`docs/LABEL_REVIEW.md`).

처음 정제가 놓친 오류 – 처음 무결성 검사는 "같은 약 박스의 중복"만 확인해, **다른 약 두 개가 같은 좌표에 라벨된 경우**를 통과시켰다. 8장의 오류 분석에서 "학습한 약을 신뢰도 0.96~0.98로 틀렸다"고 나온 사례를 원본과 대조하다가, 실제로는 모델이 맞고 라벨이 틀린 4장을 찾았다. 4장을 고친 뒤 **5-Fold와 최종 모델을 모두 다시 학습**했고, 이 보고서의 5-Fold·OOF·제출 수치는 수정된 라벨 기준이다. 모델 예측으로 찾은 후보는 모델이 같이 틀린 오류를 놓칠 수 있어 탐지 재현율은 알 수 없다.

최종 무결성 검사 (코드로 자동 확인): 모든 이미지에서 파일명의 약 목록 = 라벨의 약 목록 · 범위 밖·크기 0 박스 0 · 같은 약 중복 0 · 다른 약끼리 같은 좌표(IoU ≥ 0.9) 0 · YOLO 라벨 → 픽셀 좌표 왕복 오차 < 0.001px.

4. 검증 전략

같은 조합의 다른 각도 사진이 학습과 검증에 나뉘어 들어가면, 모델은 거의 같은 장면을 다시 맞히는 셈이 되어 점수가 부풀려진다. 이 프로젝트에서 가장 중요한 설계는 모델이 아니라 이 누수를 막는 분할이었다.

- scikit-learn의 StratifiedGroupKFold[10]를 썼다.
- **Group = 조합**: 한 조합의 사진(1~3장)을 반드시 같은 fold에 넣는다 (누수 0건을 코드로 검사).
- **Stratify = 이미지의 가장 희귀한 클래스**: 희귀 약이 fold에 고르게 퍼지도록 한다.
- 5-Fold는 실험 비교에만 쓰고, 최종 제출 모델은 232장 **전체**로 학습한다 (7장).

Fold	검증 이미지	검증 조합	검증 박스	학습에 없는 약	베이스라인 mAP50-95
0	47	23	156	5	0.836
1	46	22	153	3	0.900
2	46	23	150	1	0.936
3	46	22	153	7	0.763
4	47	24	159	3	0.879

표 4-1. fold 구성과 베이스라인(YOLO11s) 점수 (수정 라벨 기준). 처음 보는 약 수와 점수 순위가 정확히 반대다.

4.1 open-set 상한과 비교 지표

조합 단위로 나누면 한 조합에만 있는 약은 검증될 때 반드시 학습에 없다. 56종 중 **19종이 한 fold에만** 있어, 5개 fold의 검증 예측을 합친 OOF(out-of-fold) mAP의 상한은 37/56 = **0.661**이다. 따라서 56종 OOF는 모델보다 분할 구조에 좌우된다.

> **비교 지표의 결정** – 모델·앙상블은 2개 이상 fold에 있는 **37종만으로 다시 잰 OOF**(이하 37종 조건부 OOF)로 비교한다. 어려운 희귀 19종을 정답·예측 양쪽에서 뺀 값이므로 **같은 조건에서 모델을 비교하는 진단값**이며, 56종 Kaggle 점수의 추정치가 아니다. 56종을 모두 학습하는 최종 모델에서 희귀 19종이 실제로 얼마나 맞을지는 이 데이터로는 잴 수 없다.

fold 하나(독립 조합 23개)로는 0.005 이하의 차이를 구분할 수 없다. 그래서 fold 0에서 빠르게 탐색하고, 최종 후보는 5-Fold로 다시 비교하는 2단계 절차를 썼다.

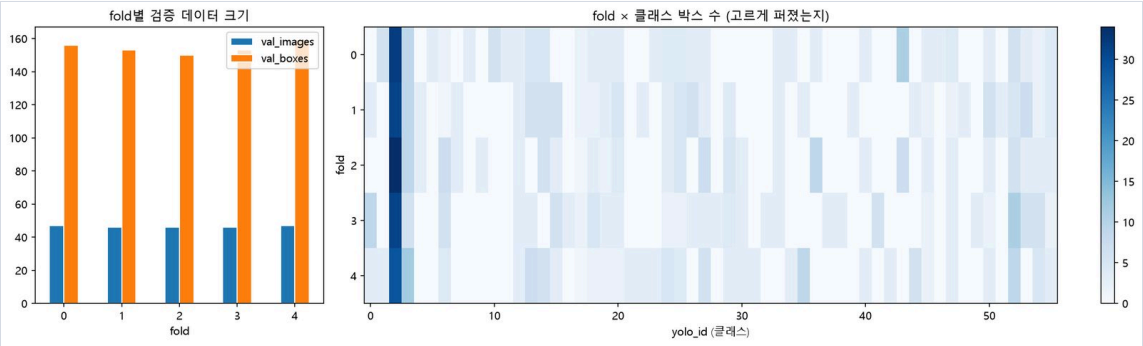


그림 4-1. fold별 클래스 분포

5. 모델과 실험 설계

5.1 모델 선택

데이터가 232장뿐이라 처음부터 학습하는 모델은 맞지 않는다. COCO[2]로 사전학습된 **YOLO11**(Ultralytics)[1]을 파인튜닝했다. 한 단계로 위치와 클래스를 함께 예측해 빠르고, 크기(n / s / m)를 바꿔 용량을 비교하기 쉽다. 약 이름만 따로 판별하는 2단계 구조를 위해서는 분류기 3종(VGG16[7] · ResNet50[8] · EfficientNet-B0[9])을 같은 조건에서 비교했다 (6.3절).

5.2 실험 원칙

- **한 번에 한 가지만 바꾼다.** 모든 실험은 베이스라인 설정 파일을 복사해 값 하나만 바꾼다. 점수가 변하면 원인을 설명할 수 있다.
- **실험 하나 = 설정 파일 하나.** `python scripts/run_experiment.py --config configs/<실험>.yaml` 한 줄로 학습 → 평가 → 테스트 예측 → 제출 파일 검사 → 실험 기록까지 실행된다.
- **검증 데이터로 고른 값은 그 데이터로 평가하지 않는다.** 앙상블 설정·전처리 설정처럼 고를 것이 있으면 선택 편향을 따로 점검한다.

5.3 베이스라인 (E0)

YOLO11s · 640px · Ultralytics 기본 증강 · 100 에포크(조기 종료 30) · fold 0. mAP50-95 **0.835**, mAP50 0.847, 학습 5.7분. 라벨 4장을 고친 뒤(3장) 같은 설정으로 다시 학습한 값은 0.836이다.

> **라벨 수정 전 탐색 기록** – 5.3절의 그림·표와 6.1~6.4절(fold 0 탐색, 2단계, 분류기, Copy-Paste)은 오류 분석에서 라벨 오류 4장을 찾기 **전**에 한 실험이다. 결론을 바꿀 만큼 큰 차이(0.01 이상)만 근거로 썼고, 수정 후 수치(6.5절 이후)와 직접 비교하지 않는다. 5-Fold 비교(6.5~6.7절), 최종 모델(7장), 결과 분석(8장)은 모두 수정된 라벨로 다시 학습·평가한 값이다.

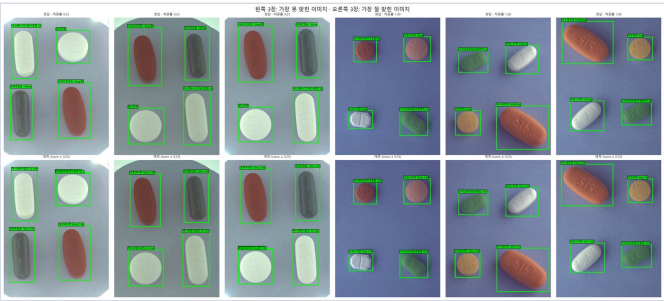


그림 5-1. 위: 정답, 아래: 예측. 위치는 모두 맞고, 처음 보는 약을 비슷한 약으로 예측

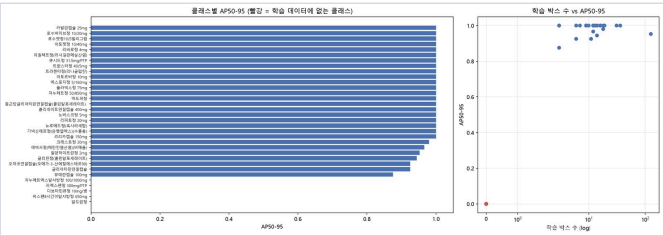


그림 5-2. 클래스별 AP (빨강 = 학습에 없는 약)

발견	근거	다음 결정
오류는 **위치가 아니라 처음 보는 약의 이름**	학습한 약 AP 0.985 / 처음 보는 약 5종 AP 0.000	위치와 이름을 나눠 푸는 2단계 모델 시도
처음 보는 약을 **비슷한 약으로 확신**	다보타민큐정 → 트루비타정 (신뢰도 0.96)	희귀 약 보강 (Copy-Paste), 서비스 설계 시사점 (11장)
이미지당 상위 4개 제한은 **손해**	mAP50-95 0.835 → 0.822	가설 기각. 제출에는 모든 예측 유지

6. 실험 결과와 의사결정

6.1 fold 0 탐색: 해상도 · 모델 크기 · 증강

ID	변경 (E0 대비 하나만)	mAP50	mAP50-95	학습 시간	판단
E0	베이스라인 YOLO11s · 640px	0.847	0.835	5.7분	기준
E1	해상도 960px	0.824	0.811	11.6분	하락
E1	해상도 1280px	0.837	0.830	41.3분	개선 없음, 7배 느림
E2	YOLO11n	0.842	0.823	6.3분	하락
E2	**YOLO11m**	**0.847**	**0.839**	**30.8분***	**최고, 5-Fold 후보**
E2	YOLO26s (최신 구조)	0.828	0.810	4.3분	하락
E3	상하 뒤집기 증강	0.847	0.833	5.3분	차이 없음
E3	밝기 증강 강화 (hsv_v 0.4 → 0.6)	0.847	0.837	5.6분	+0.002, 판단 불가

표 6-1. fold 0(47장) 결과, 라벨 수정 전 기록. * 다른 학습과 GPU를 함께 쓴 구간이 있어 시간이 부풀려짐 (5-Fold에서는 fold당 9~12분).

강한 후보들의 mAP50이 0.847로 같다. fold 0 검증에는 학습에 없는 약이 5종 있어 이 분할에서 가능한 mAP50의 최댓값이 28/33 = **0.848**이기 때문이다. 즉 fold 0에서는 **이미 상한에 닿아** 모델 간 차이가 드러나지 않는다. 남은 여지는 박스 정밀도(mAP50-95)와 데이터 전체 활용이므로, 다음 비교는 5-Fold로 옮겼다.

6.2 처음 보는 약 문제: 2단계 모델

오류가 "이름"에서 나오므로 위치(알약 찾기)와 이름(약 판별)을 나눠, YOLO가 찾은 박스를 별도 분류기로 다시 판별하는 2단계 구조를 시도했다.

6.3 분류기 3종 비교 (5-Fold)

2단계 모델의 약 이름 판별기 후보를 **같은 증강·학습 설정에서 구조만 바꿔** 비교했다. 정답 박스를 잘라 학습한 약만으로 평가한 값이라 실제 검출 성능이 아니라 **분류기 구성요소의 낙관적 진단값**이다.

분류기	정확도	F1 (macro)	log loss	학습 시간	파라미터
EfficientNet-B0	**0.993 ± 0.008**	**0.994 ± 0.006**	**0.166**	**2.1분**	**4.1M**
VGG16	0.993 ± 0.008	0.989 ± 0.015	0.153	5.5분	134.5M
ResNet50	0.992 ± 0.009	0.987 ± 0.015	0.217	2.1분	23.6M

표 6-2. 5-Fold 평균 ± 표준편차. 출처: reports/experiments/classifiers_f*.csv

EfficientNet-B0을 골랐다. F1이 가장 높고 VGG16의 1/33 파라미터로 2.6배 빠르다. 그러나 YOLO 박스와 결합한 2단계 모델은 fold 0에서 0.832 ~ 0.834로 YOLO 단독(0.835)을 넘지 못했다. YOLO가 이미 **학습한 약은 거의 다 맞히고 있어** 분류기가 더할 여지가 없었고, 처음 보는 약은 분류기도 학습한 적이 없기 때문이다. 분류기를 바꾸는 것으로는 open-set 문제를 풀 수 없다는 것이 이 실험의 결론이다.

6.4 효과가 없었던 시도 (음성 결과)

시도	결과	해석
Copy-Paste 합성[6] 400장	0.823 (−0.012)	이 설정만 기각. 합성이 원본(185장)의 2배를 넘어 합성 특유의 경계·배경을 학습했을 가능성. 비율을 낮춘 재실험 후보
2단계 (검출 + 분류기)	0.832 ~ 0.834	6.3절. 학습한 약은 이미 맞히고, 처음 보는 약은 분류기도 모른다
1-클래스 검출기 (위치만)	위치 0.939	56-클래스 YOLO의 위치 성능(클래스 무시 0.962)보다 낮다 → 클래스 정보가 위치 학습에도 도움
이미지당 상위 4개 제한	0.822 (−0.013)	mAP는 낮은 점수 예측까지 순위로 평가하므로, 잘라 내면 재현율을 잃는다
CLAHE 전처리	fold 2↑ 3↓	6.5절. 라벨 수정 전후 모두 개선이 불확실해 미채택

표 6-3. 결과는 fold 0 mAP50-95, 라벨 수정 전 기록 (CLAHE는 수정 후 5-Fold). 기각한 시도도 근거와 함께 남겨 같은 실험을 반복하지 않게 했다.

6.5 전처리: CLAHE 전후 비교 (5-Fold)

EDA에서 본 Train/Test 밝기 차이를 이미지마다 국소 대비를 평탄화하는 CLAHE[5]로 줄일 수 있는지 확인했다. 알약 색은 클래스를 가르는 단서이므로 LAB의 밝기 채널에만 적용했고, 설정값은 검증 점수로 고르지 않고 OpenCV 기본값(clip 2.0, tile 8×8)으로 고정했다. 학습·검증·테스트 모두 같은 함수를 거친다.



그림 6-1. CLAHE 전후. 어두운 Test 이미지가 밝아지지만 배경 질감과 알약 둘레의 어두운 테두리도 강해진다

분포 (Test − Train)	원본	CLAHE
밝기 차이	−5.55	−3.25
대비 차이	+2.88	+2.98

밝기 차이는 40% 줄었지만, 대비는 Train과 Test가 함께 커져 차이가 그대로였다.

부트스트랩 단위 – 같은 조합의 사진은 서로 독립이 아니다. 분할과 같은 단위인 조합 114개를 복원 추출(1000회)[11]해 두 실험의 차이를 짝지어 계산했다. 이미지 단위로 뽑으면 구간이 지나치게 좁아진다.

YOLO11s 5-Fold	fold 0 / 1 / 2 / 3 / 4	fold 평균	37종 조건부 OOF
원본	0.836 / 0.900 / 0.936 / 0.763 / 0.879	0.8626	0.956
CLAHE	0.833 / 0.900 / 0.943 / 0.748 / 0.886	0.8618	0.962
차이	2개 fold 상승 · 3개 fold 하락	−0.0008	+0.005 95% 구간 −0.003 ~ +0.018 (개선 확률 88%)

표 6-4. 수정 라벨로 두 실험을 모두 다시 학습한 값 (라벨 수정 전에도 2개↑ 3개↓, 37종 OOF +0.011, 구간 −0.006 ~ +0.027로 같은 결론). 출처: reports/experiments/preprocess_clahe_stats.csv, compare_e0_baseline_vs_e4_clahe.csv

결정: 미채택. fold 단위로는 방향이 엇갈리고(처음 보는 약이 가장 많은 fold 3에서 −0.015), 합친 OOF의 개선도 구간이 0을 포함한다. 라벨을 고쳐 다시 학습해도 결론이 같았고, 대리지표로 다시 봐도 같았다 (37종 OOF +0.006, 구간 −0.005 ~ +0.020, 2개 fold 상승 · 3개 하락). 밝기 차이는 학습 중 HSV 증강이 이미 다루고 있어 전처리로 얻을 몫이 작았던 것으로 본다.

6.6 5-Fold 최종 후보 비교와 앙상블

모델	fold별 mAP50-95 (0 / 1 / 2 / 3 / 4)	fold 평균 ± 표준편차	OOF 56종	OOF 37종 (조건부)
YOLO11s	0.836 / 0.900 / 0.936 / 0.763 / 0.879	0.863 ± 0.067	0.634	0.956
YOLO11m	0.837 / 0.900 / 0.924 / 0.732 / 0.884	0.855 ± 0.076	0.622	0.941
WBF 11s + 11m (2:1, IoU 0.6)	–	–	**0.638**	**0.964**

표 6-5. 수정 라벨 기준. 출처: reports/cv_summary.csv, reports/experiments/oof_analysis.csv, wbf_oof.csv

- **단일 모델로는 YOLO11s가 낫다**: fold 평균(+0.007)과 37종 OOF(+0.015) 모두 11s가 높고, 학습도 약 1.5배 빠르다. 라벨 수정 전에는 두 지표의 방향이 엇갈렸다.
- **두 모델의 WBF[4]는 단일 최고보다 높다**: 37종 OOF 0.956 → 0.964 (+0.008, 대리지표로는 0.938 → 0.950, +0.012). 8.2절에서 IoU별로 나누면 IoU 0.95 한 곳의 +0.040이 10개 임계값 평균에 +0.040 / 10 = +0.004를 더해, 차이의 약 절반이 이 구간에서 관찰된다. 박스 좌표 평균이 위치를 다듬는다는 가설과 맞지만, 고정 신뢰도에서 센 실패 유형은 mAP의 가법 분해가 아니므로 원인으로 단정하지 않는다.

> **설정 선택 편향 점검 (근사 메타 검증)** – WBF의 IoU 임계값과 모델 가중치 12개 조합 중 최댓값을 같은 OOF에서 고르면 낙관적이다. 그래서 fold 하나를 보류하고 나머지 4개 fold로 설정을 고른 뒤 보류 fold에만 적용하는 과정을 5번 반복했다. **가중치는 5번 모두 2:1**이었다. 처음에는 mAP50-95로 평가해 IoU 0.7(3회)을 택했는데, 이때 전체 OOF의 0.6과 0.7은 0.9636으로 동률이었다. 대리지표로 같은 절차를 다시 돌리자 **IoU는 0.6이 3번 · 0.7이 2번** 뽑혔고 전체 OOF도 0.6이 근소하게 높아(0.9502 vs 0.9495), 최종 설정을 **2:1, IoU 0.6**으로 바꿨다. 차이가 작아 "0.6이 더 좋다"는 근거가 아니라 규칙을 따른 선택이다. 보류 예측 합산(대리지표 0.949)은 독립된 성능 추정치가 아니라 설정 안정성을 점검한 값이다.
>
> 라벨 수정 전에는 같은 절차가 1:1을 골랐다. 절차를 고정하고 결과를 따랐으며, 1:1과 2:1의 차이(0.002)는 결론을 바꿀 크기가 아니다.
>
> 다만 설정을 고를 때 쓴 다른 fold의 모델은 보류 fold를 학습에 포함했으므로 완전히 격리된 추정은 아니다. 엄밀한 nested CV는 보류 fold를 뺀 4개 fold 안에서 모델을 다시 학습해야 해, 저장된 예측만으로는 할 수 없다. 그래서 이 결과는 "설정 선택이 안정적인가"의 근거로만 쓴다.

6.7 하이퍼파라미터 · TTA

학습률 (R11) – `optimizer=auto`가 실제로 고른 값(AdamW, lr0 0.000167)을 기준으로 학습률 하나만 바꿔 fold 0에서 비교했다. 판단 규칙은 실행 전에 설정 파일에 적어 두었다: "E0보다 0.005 이상 좋을 때만 5-Fold로 확인한다."

학습률	fold 0 mAP50-95	E0 대비	판단
0.000167 (auto, E0)	0.8356	–	기준
0.0005 (3배)	0.8381	+0.0025	사전 기준(+0.005) 미달 → 5-Fold 생략
0.00005 (0.3배)	0.8269	−0.0087	하락

표 6-6. 수정 라벨 기준. 출처: configs/e5_lr_high.yaml, e5_lr_low.yaml, reports/experiments.csv

auto 값을 유지했다. fold 하나(독립 조합 23개)로는 0.005 이하의 차이를 구분할 수 없으므로, 3배의 +0.0025는 개선 근거로 쓰지 않는다. 배치 크기는 실험하지 않았다.

TTA (R14) – 다시 학습하지 않고, 이미 학습한 5-Fold 모델로 검증 예측만 TTA(좌우 뒤집기 + 0.83 · 0.67배 축소, Ultralytics 기본)로 다시 만들어 기준 예측과 짝지어 비교했다. fold k 모델은 fold k 이미지만 예측하므로 학습 때와 같은 누수 없는 OOF다 (`scripts/predict_oof.py`).

37종 조건부 OOF	TTA 없음	TTA	차이 (조합 부트스트랩 95% 구간)	fold별	개선 확률
YOLO11s	0.956	0.952	−0.004 (−0.011 ~ +0.002)	3개↑ 2개↓	9%
YOLO11m	0.941	0.936	−0.005 (−0.010 ~ +0.002)	1개↑ 4개↓	11%

표 6-7. 출처: reports/experiments/compare_e0_baseline_vs_e0_baseline_tta.csv, compare_e2_yolo11m_vs_e2_yolo11m_tta.csv

결정: 미채택. 두 모델 모두 합친 OOF가 내려갔고 개선 확률은 10% 안팎이다. 대리지표로 다시 봐도 같았다 (37종 OOF 11s −0.007, 구간 −0.015 ~ +0.002, 3개 fold 상승 · 2개 하락, 개선 확률 7% / 11m −0.012, 구간 −0.018 ~ 0.000, 5개 fold 모두 하락, 개선 확률 3%). 고정된 카메라로 비슷한 크기의 알약을 찍은 데이터라 축소 변환이 학습 분포에 없는 크기를 만들고, 합쳐진 박스가 가장 엄격한 IoU에서 정밀도를 잃었을 수 있다 (확인하지 않은 가설).

7. 최종 후보 모델과 제출

7.1 전체 데이터 학습

최종 후보 모델은 232장 **전체**로 학습한다. 이때는 검증 데이터가 학습에 포함되므로 검증 점수로 가중치를 고를 수 없다. 검증을 끄고, 정해진 에포크만큼 학습한 **마지막 가중치(last.pt)**를 쓴다.

에포크는 fold별 최고 에포크의 **중앙값**으로 정했다 (수정 라벨 기준 YOLO11s 80/81/86/26/59 → 80, YOLO11m 80/90/50/44/80 → 80. 수정 전에는 50 · 83). 데이터가 fold 학습보다 25% 많고 학습률 스케줄이 총 에포크에 묶여 있어 최적이라는 보장은 없는 **휴리스틱**이다. 대신 fold별 학습 기록으로 민감도를 확인했다.

고정 에포크 후보	YOLO11s: 최고점 대비 평균 손해	YOLO11m: 최고점 대비 평균 손해
P25 (59 / 50)	0.006*	0.011
중앙값 (80 / 80)	**0.003***	**0.001***
P75 (81 / 80)	0.004*	0.001*

표 7-1. * 조기 종료로 그 에포크까지 학습하지 않은 fold(주로 처음 보는 약이 7종인 fold 3)가 빠져 유리하게 치우친 값. 출처: epoch_sensitivity.csv

중앙값에서의 평균 손해는 0.003 이하지만, 이것은 **80 에포크까지 학습한 4개 fold에서만 잰 참고값**이다. 11s · 11m 모두 fold 3이 26~44 에포크에서 최고였다가 조기 종료되어 빠졌고, fold 학습은 100 에포크 학습률 스케줄인데 최종 학습은 80 에포크 스케줄이라 같은 에포크의 상태가 다르다. 그래서 이 표로 "최고점 주변이 평평하다"를 입증하지 않으며, 80 에포크는 최적값이 아니라 **중앙값 휴리스틱**으로만 채택했다. 처음 보는 약이 많은 분할에서는 더 짧은 학습이 나았을 수 있다.

7.2 제출 후보와 결과

제출 파일	구성	37종 조건부 OOF (대리지표)	Kaggle public
final_11s_11m_wbf_iou06	**YOLO11s + YOLO11m WBF (2:1, IoU 0.6)**	**0.950**	**0.41349**
final_11s_11m_wbf	YOLO11s + YOLO11m WBF (2:1, IoU 0.7)	0.950	0.41410
final_yolo11s_single	YOLO11s 단일	0.938	0.40954
final_yolo11m_single	YOLO11m 단일	0.922	0.39427

표 7-2. 테스트 842장 모두 예측 있음. 점수 0.5 이상 박스가 이미지당 3.6~3.7개로 학습 데이터(3~4개)와 일치.

순위는 맞았고, 절댓값은 크게 어긋났다. 앙상블 > 11s > 11m 순서는 OOF와 같다. IoU 0.6과 0.7은 OOF(0.0007)와 public(0.0006) 모두 차이가 작고 방향은 반대라 구분되지 않는다. 미리 정한 대로 public 점수를 보고 주력을 바꾸지 않았다.

낮은 점수의 원인은 확정하지 못했다. 37종 값이 Kaggle 추정치가 아니라는 점은 이미 밝혔지만, 56종 전체 대리지표 0.628과 비교해도 public이 낮다. 테스트 정답이 비공개라 아래는 가설과 간접 근거다.

- **학습에 없는 클래스 (유력):** 대회 안내가 테스트에 이런 클래스가 있다고 밝힌다. 클래스 평균 지표에서 이 클래스들의 AP는 0에 가까우므로 점수가 비례해 줄어든다. 네 후보의 public ÷ OOF 비율이 0.427~0.437로 비슷한 것은 이 설명과 어긋나지 않지만 증거로는 약하다.
- **이것만으로 전부 설명되는지는 불확실하다:** AP 0.95 · 학습 56종이 모두 테스트에 있다고 가정하면 0.413은 전체 약 129종, 즉 없는 클래스 약 73종에 해당한다. 반면 테스트 예측의 신뢰도 분포를 OOF의 처음 보는 약과 비교하면 그런 박스는 약 9~11%로 추정된다(최종 모델은 전체 데이터로 학습해 신뢰도 분포가 달라 거친 값이다). 둘이 맞으려면 없는 클래스마다 박스가 아주 적어야 한다.
- **다른 가능성:** 한 조합에서만 학습한 19종의 낮은 AP, 안내에 언급된 데이터 오류, 주최 측 평가 구현과 대리지표의 차이, public 표본의 영향. 이번 자료로는 나눌 수 없다.

리더보드 비교 (11/05): 상위 4팀 0.611~0.634, 기준 제출 0.589로 이 프로젝트의 주력보다 약 0.2 높다. Public은 테스트의 약 50%만 반영한다.

놓친 개선 방향과 후속 실험: 대회 안내상 금지 파일 외의 AI Hub 데이터를 추가할 수 있었지만 제출 전에는 검토하지 않았다. 제출 뒤 허용된 조합 라벨(금지 묶음 제외 7묶음)을 분석하니 약 116종이었고, 대회 56종 중 54종이 겹치며 62종은 새 약이었다. 그중 1묶음(1,437장, 76클래스)을 더해 15 에포크만 시험 학습했더니 대회 fold 0의 mAP50-95가 0.835에서 0.937로 올랐다. fold 하나(47장)의 시험값이지만, Kaggle public도 같은 YOLO11s 단일 기준 0.40954에서 0.52212로 올랐다. 이 시험 제출은 후보가 아니며 위 표에 넣지 않았다. 전체 데이터 학습은 이 보고서 작성 시점에 진행 중이다. "테스트가 약 118종이고 격차의 대부분이 이 때문"이라는 설명은 아직 가설이다.

8. 결과 분석

현재 최종 후보와 같은 구성(YOLO11s + YOLO11m, WBF 2:1, IoU 0.6)의 5-Fold OOF 예측 232장을 다시 나눠 보았다. 새로 학습한 것은 없다. 목적은 mAP 한 숫자 뒤에서 **어디서 점수를 잃는지** 찾는 것이다. 출처: `scripts/error_analysis.py`, `reports/experiments/error_*.csv`.

> **이 분석이 데이터를 고쳤다** – 처음 이 장을 썼을 때는 "학습한 약끼리도 신뢰도 0.96~0.98로 틀린다"는 결론이 있었다. 그 사례를 원본과 대조하자 4장 모두 모델이 맞고 라벨이 틀렸다 (보고서 3장 "데이터 정제"의 감사 D·E: D 3장 + E 1장). 라벨을 고쳐 전체를 다시 학습했고, 그 결론은 **철회**했다. 아래 수치는 모두 수정된 라벨 기준이다.

8.1 클래스별 AP

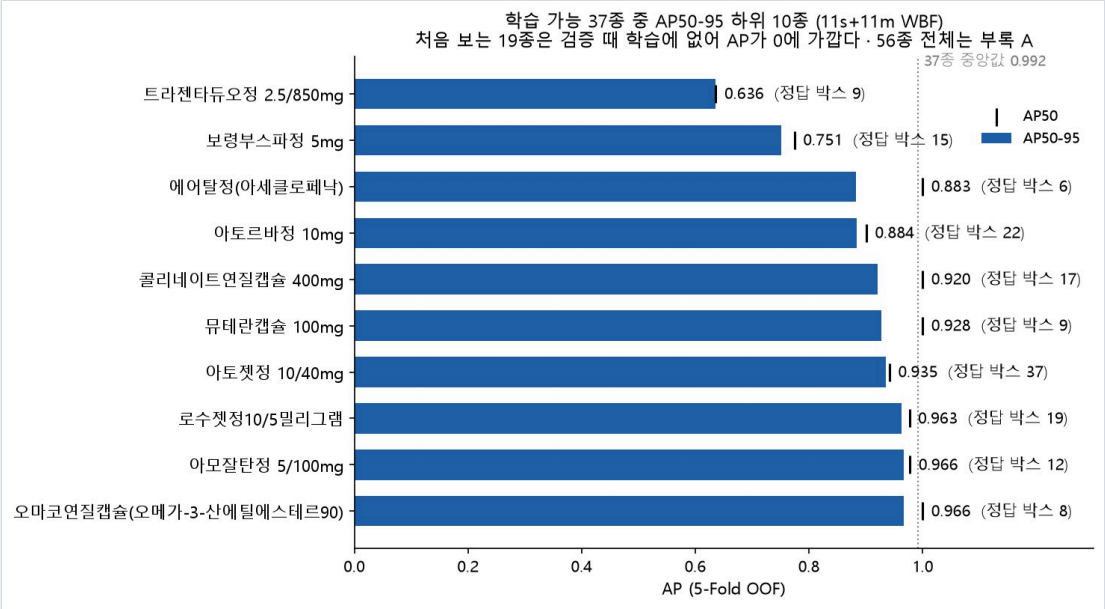


그림 8-1. 학습 가능 37종 중 AP50-95 하위 10종. 56종 전체 값은 부록 A.

37종의 AP50-95 중앙값은 **0.992**이고, 28종은 AP50이 1.0이다. 0.9 미만은 4종뿐이다. 처음 보는 19종은 검증될 때 학습에 없어 18종이 0이다. 동아가바펜틴정만 0.100인데, 학습하지 않은 클래스 출력이 낸 신뢰도 0.003 미만의 예측 몇 개가 우연히 그 알약 위에 놓인 결과다 (누수 아님, 같은 fold에 이 약의 학습 박스 없음).

AP 하위 (37종 안)	AP50-95	AP50	정답 박스	검증 때 학습 박스 (평균)
트라젠타듀오정 2.5/850mg	0.636	0.636	9	4.0
보령부스파정 5mg	0.751	0.775	15	8.4
에어탈정(아세클로페낙)	0.883	1.000	6	3.0
아토르바정 10mg	0.884	0.901	22	16.9
콜리네이트연질캡슐 400mg	0.920	1.000	17	13.3

표 8-1. "검증 때 학습 박스"는 그 박스가 검증될 때 나머지 fold에 있던 같은 약의 박스 수. 출처: error_per_class.csv

학습 박스 수와 AP 사이에는 **단조 관계가 관찰되지 않았다** (Spearman ρ = −0.06, n = 37, 탐색적). 22박스나 있는 아토르바정도 하위권이다. 하위 약의 손실은 비슷하게 생긴 다른 약과의 혼동, 그리고 다른 약의 오탐에서 나왔다. 보령부스파정은 자기 박스 15개 중 11개를 맞혔지만, **처음 보는 약 5박스**(아빌리파이정 3, 졸로푸트정 2)가 보령부스파정으로 예측되어 이 클래스의 오탐이 되었다. 처음 보는 약이 학습한 약의 AP까지 깎는 경로다.

8.2 위치 정밀도: IoU 임계값별 mAP

37종 mAP	IoU 0.50	0.75	0.90	0.95	50-95 평균	75-95 평균 (대리지표)
YOLO11s	0.975	0.972	0.947	0.832	0.956	0.938
YOLO11m	0.960	0.957	0.944	0.806	0.941	0.922
WBF 11s + 11m (2:1, IoU 0.6)	**0.978**	**0.975**	**0.963**	**0.872**	**0.964**	**0.950**

표 8-2. 출처: error_per_iou.csv

- **맞힌 박스의 위치는 정확하다.** 신뢰도 0.25 이상에서 같은 약으로 맞힌 692박스의 조건부 IoU 중앙값은 0.974이고, 0.9 미만은 0.7%다. 다만 이것은 맞힌 박스만의 값이고, mAP는 IoU 0.95에서 0.87로 내려간다. 가장 엄격한 기준에서는 위치 손실이 남아 있다.
- **앙상블 이득은 IoU 0.95에서 가장 크다.** 11s 대비 +0.008 중 IoU 0.95 한 곳의 +0.040이 10개 임계값 평균에 +0.040 / 10 = +0.004를 기여해, 차이의 약 절반이 이 구간에서 관찰된다. 엄격한 구간만 평균하는 대리지표에서 앙상블 이득이 더 큰(+0.012) 이유도 여기에 있다. 6.6절의 "박스 좌표 평균이 위치를 다듬는다"는 가설을 지지하는 패턴이지만, IoU별 차이는 원인별 가법 분해가 아니므로 원인으로 단정하지 않는다.

8.3 실패 유형

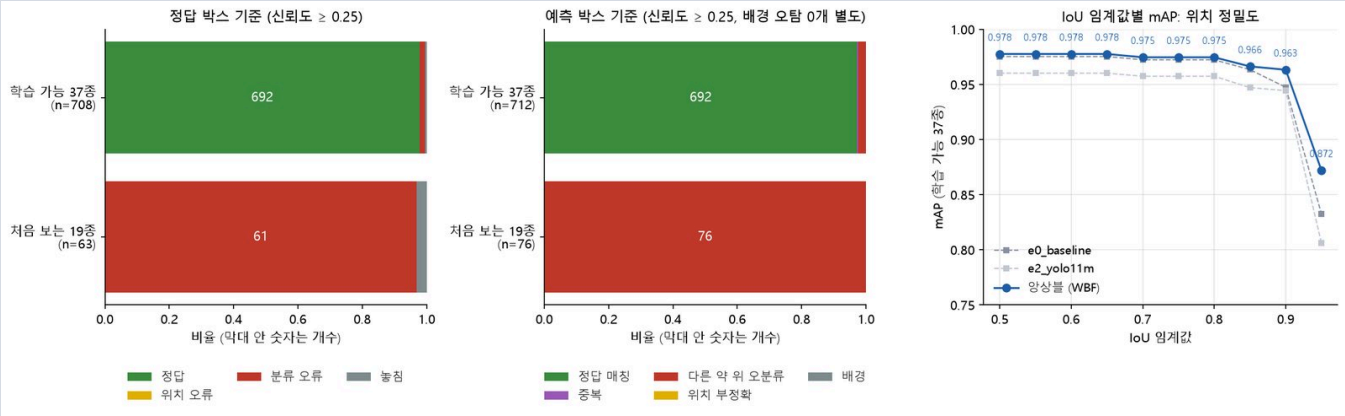


그림 8-2. 신뢰도 0.25 이상 예측 기준 실패 유형(왼쪽: 정답 박스, 가운데: 예측 박스)과 IoU 임계값별 mAP(오른쪽).

예측을 점수 순으로 하나씩 보며, 아직 배정되지 않은 정답 중 IoU가 가장 큰 것(IoU ≥ 0.5, 약 종류 무관)에 **1:1로 배정**했다. 같은 약이면 **정답**, 다른 약이면 **분류 오류**다. 남은 정답은 같은 약 예측이 0.1 ≤ IoU < 0.5로 겹치면 **위치 오류**, 아니면 **놓침**이다. 예측 하나가 겹친 두 정답에 동시에 쓰이지 않으며, 어느 정답과도 IoU < 0.1인 배경 오탐은 별도로 센다. 0.25는 Ultralytics 예측의 기본 신뢰도다. 고정 신뢰도에서 센 개수이므로 COCO mAP의 손실 분해가 아니다.

정답 박스 (신뢰도 ≥ 0.25)	정답	위치 오류	분류 오류	놓침
학습 가능 37종 (708개)	692 (97.7%)	0	12 (1.7%)	4 (0.6%)
처음 보는 19종 (63개)	0	0	61 (96.8%)	2 (3.2%)
37종, 신뢰도 ≥ 0.5	681	0	8	19

표 8-3. 출처: error_types.csv. 예측 박스 기준으로는 배경 오탐 0개, 같은 약 중복 예측 2개.

- **위치 오류와 배경 오탐은 관찰되지 않았다.** 이 단일 촬영 환경의 OOF와 신뢰도 0.25 기준에서는 알약을 "찾는" 일이 거의 해결되었고, 남은 문제는 "이름 붙이기"다.
- **학습한 약의 분류 오류는 신뢰도가 낮다.** 12개의 신뢰도 중앙값은 0.55, 최댓값은 0.82였다. 신뢰도 0.9 이상으로 틀린 학습 약은 없었다.
- **놓침(신뢰도 0.25 기준)은 사실상 낮은 신뢰도의 검출이다.** 놓친 6개(37종 4, 처음 보는 약 2) 모두 같은 자리에 IoU ≥ 0.5 박스가 있었지만 신뢰도가 0.25 미만이었고, 그중 맞는 약 이름은 1개였다.
- **처음 보는 약은 거의 모두 다른 약 이름으로 답한다** (63개 중 61개).

8.4 실패 사례

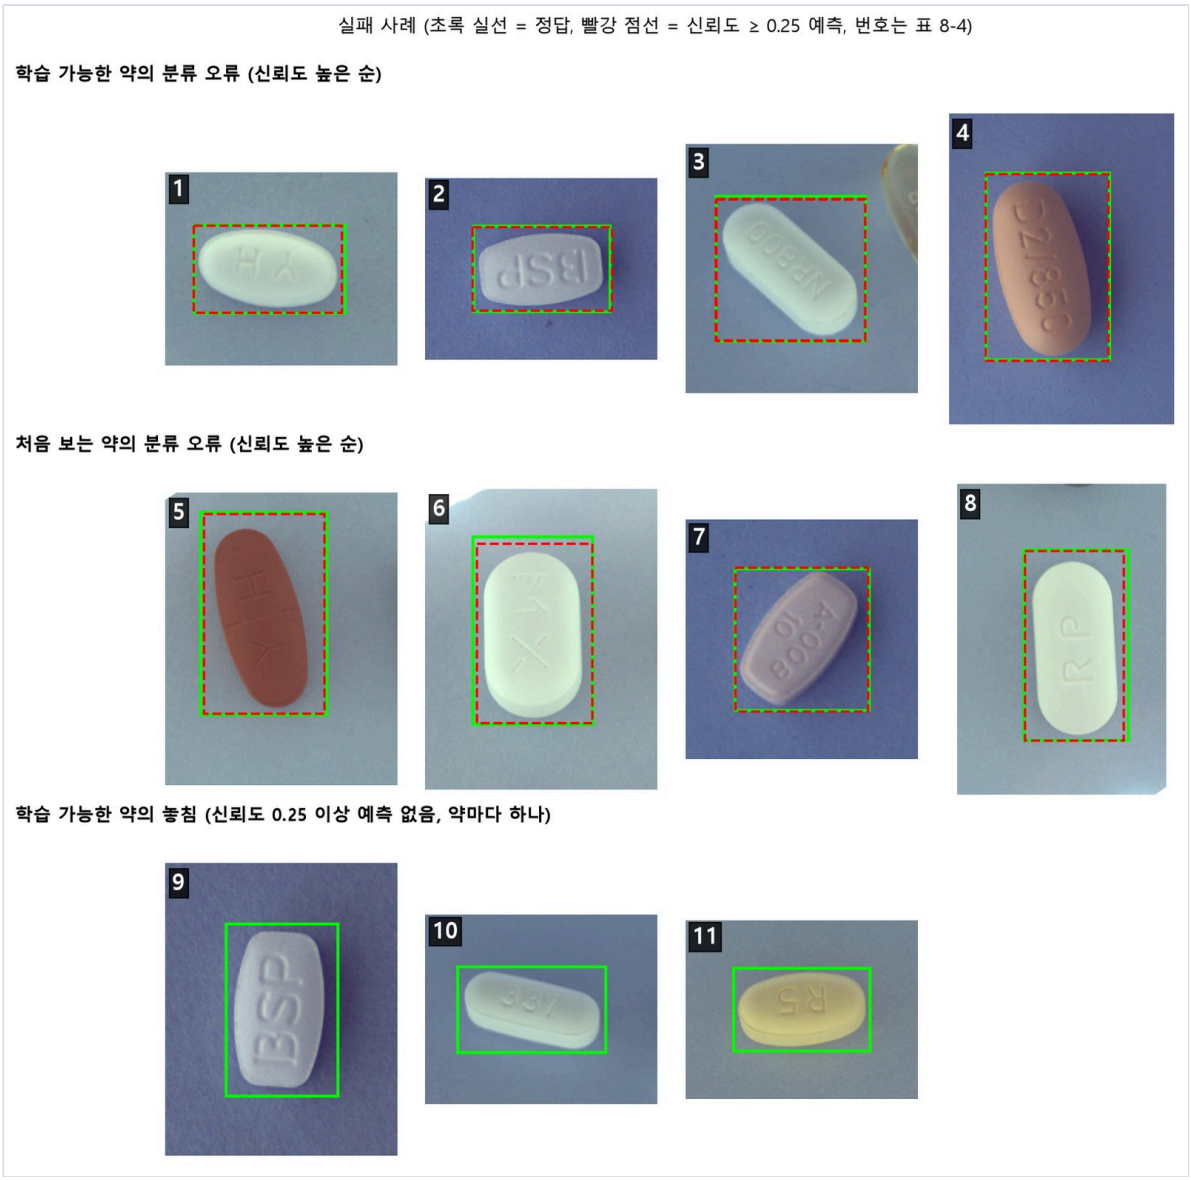


그림 8-3. (실제, 예측) 쌍마다 신뢰도가 가장 높은 사례 하나. 초록 실선은 정답, 빨강 점선은 신뢰도 0.25 이상 예측. 번호는 표 8-4.

번호	유형	실제 약	예측	신뢰도
1	학습 약 분류 오류	아토르바정 10mg	로수젯정 10/5mg	0.82
2	학습 약 분류 오류	보령부스파정 5mg	졸로푸트정 100mg	0.81
3	학습 약 분류 오류	뉴로메드정	아토젯정 10/40mg	0.62
4	학습 약 분류 오류	트라젠타듀오정 2.5/850mg	울트라셋이알서방정	0.55
5	처음 보는 약	다보타민큐정	트루비타정	0.98
6	처음 보는 약	맥시부펜이알정 300mg	리렉스펜정 300mg	0.97
7	처음 보는 약	아빌리파이정 10mg	보령부스파정 5mg	0.97
8	처음 보는 약	리렉스펜정 300mg	맥시부펜이알정 300mg	0.96
9~11	학습 약 놓침	보령부스파정 · 아토젯정 · 로수젯정	신뢰도 0.25 미만 박스만 있음	0.09~0.17

표 8-4. 출처: error_failure_cases.csv. 1~4는 IoU 0.96~0.98로 위치는 맞고 이름만 틀렸다.

- **처음 보는 약은 닮은 학습 약으로, 높은 신뢰도로 답한다.** 다보타민큐정 ↔ 트루비타정(갈색 타원형), 맥시부펜이알정 ↔ 리렉스펜정(흰색 장방형)처럼 서로 닮은 두 약이 다른 fold에 있을 때 양방향으로 혼동했다.

- **학습한 약의 오류는 흰색 정제끼리의 혼동이 많다.** 색과 모양이 비슷하면 각인 등 미세 특징이 구분에 중요할 가능성이 있는데, 사진 전체에서 각인이 차지하는 영역은 작다 (직접 검증하지는 않았다). 다만 이 경우는 신뢰도가 0.82 이하로 낮았다.

8.5 신뢰도로 처음 보는 약을 가를 수 있는가

정답 박스에 겹친 최고 신뢰도	학습 가능 37종 (708)	처음 보는 19종 (63)
중앙값	0.966	0.622
0.9 이상 비율	88.4%	**23.8%**
0.5 미만 비율	2.7%	23.8%
두 번째 이름도 0.25 이상인 비율	1.1%	23.8%
AUROC (신뢰도가 낮을수록 처음 보는 약)	0.884 (95% 구간 0.794 ~ 0.955, 조합 단위 부트스트랩 1000회)	

표 8-5. 출처: error_unknown_summary.csv. 같은 조합의 사진은 서로 독립이 아니어서 조합 단위로 다시 뽑았다.

신뢰도는 처음 보는 약에서 낮은 편이지만(AUROC 0.884), **처음 보는 약의 24%는 신뢰도 0.9 이상으로 다른 약이라고 답했다.** 동일 OOF 표본에서 처음 보는 약의 90%를 거르는 탐색적 operating point를 잡으면 학습한 약 박스의 28%도 함께 거부된다 (그 점의 신뢰도 0.954. 같은 데이터로 고른 값이라 낙관적이며 운영값이 아니다). 이 수치는 WBF 설정에 민감하다. IoU 0.7에서는 같은 값이 30%, AUROC 0.842, 거부 55%였다. mAP가 거의 같은 두 설정에서 이만큼 달라지므로 표본 63박스의 불안정성을 고려해 방향만 읽어야 한다. 11장의 "신뢰도 임계값만으로는 부족하다"는 판단의 정량 근거다. 처음 보는 약이 63박스뿐이고 촬영 환경이 하나여서, 이 표로 운영 임계값을 정하지는 않는다.

8.6 테스트 예측 예시

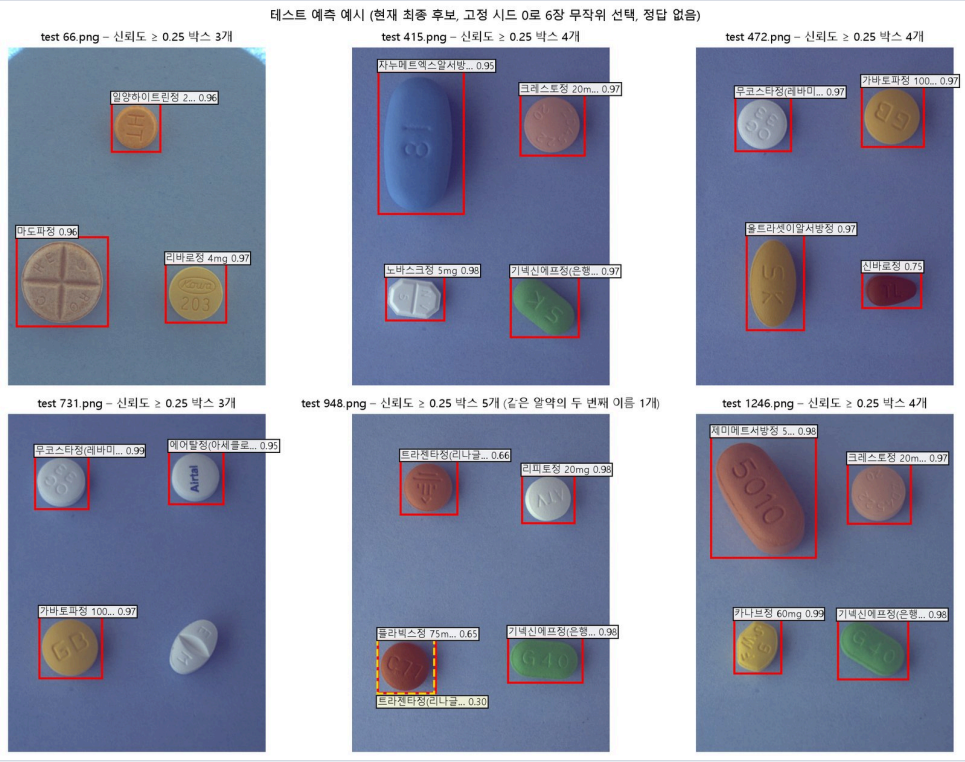


그림 8-4. 현재 최종 후보의 테스트 예측 (고정 시드 0으로 6장 무작위 선택, 신뢰도 0.25 이상). 노란 점선은 같은 알약에 붙은 두 번째 이름이다. 테스트는 정답이 없어 정확도를 판단하지 않는다.

신뢰도 0.25 이상 박스를 IoU ≥ 0.5로 묶은 "한 알약"에 이름이 두 개 이상 붙은 비율은 OOF 3.0%(765묶음 중 23), 테스트 3.7% (3,124묶음 중 117)였다. 정답이 없어 테스트가 더 어렵다는 증거로 해석하지 않는다. 다만 정답 없이 계산할 수 있으므로, 서비스에서 "사용자 확인 필요" 사례의 빈도를 지켜보는 **모니터링 후보 지표**로 쓸 수 있다.

> **정리** – 현재 최종 후보는 학습한 약의 위치를 정확히 찾고(맞힌 박스의 IoU 중앙값 0.974), 학습한 약을 틀릴 때는 신뢰도가 낮다. 점수와 안전 모두에서 가장 큰 문제는 **처음 보는 약에 높은 신뢰도로 다른 이름을 붙이는 것**이다. 이번에 시험한 해상도 · 모델 크기 · crop 분류기 범위에서는 개선을 확인하지 못했다(6.1~6.3절). 닮은 약의 혼동은 이번에 시도한 고해상도 입력(6.1절)과 crop 분류기(6.3절)에서 개선이 확인되지 않아 남은 과제로 둔다(12장).

9. 재현성과 코드 품질

노트북은 분석과 해석을, 공통 코드는 `src/pilldet/` 패키지가 맡는다. 노트북과 스크립트가 같은 함수를 불러 쓰므로 결과가 어긋나지 않는다.

구성	역할
`src/pilldet/` (17개 모듈)	경로 탐색, 라벨 정제, 조합 단위 분할, YOLO/COCO 변환, 학습, 예측, COCO 평가, WBF 직접 구현, 전처리, 제출 파일 검사
`scripts/`	데이터 준비, 실험 실행(`--fold`, `--skip-train`), 5-Fold 집계, OOF 분석, 오류 분석, 짝지은 비교, 에포크 민감도, 제출 생성
`configs/`	실험 하나 = 설정 파일 하나. 베이스라인에서 값 하나만 바꾼 파일들
`tests/`	단위 테스트 함수 40개 (매개변수 포함 42개 케이스): 좌표 변환, 분할 누수, 평가, 실패 유형 분류, WBF, 제출 형식, 전처리 일치, 라벨 검수 결정 적용 · 형식 · 의미 검사, 감사 출처 해시, 콘솔 인코딩, 검사 로직

9.1 "틀린 숫자가 조용히 나오지 않게" 하는 자동 검사

- **OOF 완전성**: fold 결과 파일 누락, 다른 fold 이미지 섞임, 예측 없는 이미지, 중복 행이 있으면 계산을 멈춘다.
- **학습 설정 스냅샷 대조**: 학습을 건너뛰고 평가만 다시 할 때 현재 설정과 학습 당시 기록(`args.yaml`)이 다르면 멈춘다. TTA 재예측도 fold 모델이 그 fold의 데이터로 학습됐는지 확인한 뒤 실행한다.
- **라벨 검수 결정의 적용 조건**: 결정마다 검수 때 본 두 박스의 좌표를 함께 적고, 현재 라벨이 그 좌표와 1px 안에서 같을 때만 적용한다. 이미 고친 결과에 다시 적용하면 건너뛰므로(라벨 교환이 원상복귀하지 않음) 몇 번 실행해도 같고, 원본이 바뀌면 엉뚱한 박스를 고치지 않는다. 고치지 않는 결정(keep_overlap)도 같은 조건이라, 두 박스가 함께 다른 곳으로 옮겨진 겹침은 무결성 검사에서 새 후보로 잡힌다. 감사 후보에는 두 약이 정확히 같은 쌍의 결정만 붙이고, 결정이 없는 후보는 "미검토"로 표시한 뒤 감사 스크립트를 실패로 끝낸다(라벨이 맞다는 기각은 keep_label 결정으로만 기록). 결정 파일의 형식(중복 ID, 같은 박스 쌍의 중복 결정, 알 수 없는 action · status, 규칙별 허용 결정, 같은 약 코드, 빈 검수자 · 근거 · 날짜, 날짜 형식, 좌표가 유한한 양수 크기인지)이 어긋나면 멈춘다. 감사 결과에는 예측 · 입력(원본 라벨 · 이미지 · fold · 검수 결정) · 코드 세 묶음의 manifest 해시를 함께 적는다.
- **전처리 일치**: 학습용으로 저장한 이미지와 예측 때 실시간으로 전처리한 배열이 픽셀 단위로 같은지 테스트한다.
- **제출 파일 검사**: 컬럼 순서, 테스트에 있는 이미지 번호, 학습에 있는 약 코드, 이미지 안의 박스, 점수 범위, 중복 예측을 제출 전에 검사하고, 예측이 없는 테스트 이미지 수를 기록한다.

9.2 재현 명령

```
pip install -r requirements.txt
python scripts/prepare_data.py                      # 정제 · 변환 · 5-Fold 분할
python scripts/run_experiment.py --config configs/e0_baseline.yaml [--fold k]
python scripts/summarize_cv.py e0_baseline e2_yolo11m
python scripts/analyze_oof.py e0_baseline e2_yolo11m
python scripts/run_experiment.py --config configs/final_yolo11s.yaml   # final_yolo11m도 같은 방식
python scripts/make_submission.py --runs final_yolo11s final_yolo11m --weights 2 1 --iou-thr 0.6 --name final_11s_11m_wbf_iou06
```

GPU 학습은 cuDNN 비결정성 때문에 같은 시드에서도 가중치가 비트 단위로 같지 않을 수 있다. 재현 기준은 5-Fold 점수가 소수 셋째 자리 수준에서 같은 것이다.

실행 환경 혼재 가능성: 설치된 pandas · Pillow가 10/30 09:34경(설치 폴더 시각) 3.0.3 · 12.3.0에서 2.3.3 · 11.3.0으로 바뀐 것으로 보이며, 원인은 확인하지 못했다. 산출물 시각 기준으로 e0_baseline fold 0(09:28 완료)과 라벨 수정 전 탐색은 이전 버전, fold 1(09:37 완료)은 교체 시점에 걸쳐 있고, 나머지 5-Fold · 최종 모델 · 제출 · 테스트는 이후 버전이다. fold별 환경을 기록하지 않아 시각으로 추정한 것이다. 두 라이브러리의 차이가 점수에 영향을 줬는지는 재실행으로 검증하지 않았다. `requirements.txt`는 최종 모델을 만든 환경의 버전이다. 새 가상환경(같은 PC, Python 3.14.6, CPU용 PyTorch)에 `requirements.txt`를 설치해 의존성 검사와 단위 테스트 37개, 라벨 감사 재현을 확인했다. 다른 PC와 GPU 학습 재현은 확인하지 않았다.

10. 업무 수행 과정

매일 업무일지(`docs/worklog/`)에 할 일 · 한 일 · 인사이트 · 고민 · 못 한 일을 남겼고, 모든 변경은 Git 커밋으로 추적된다. 요구사항 17개(R1~R17)를 첫날 추적표(`docs/PLAN.md`)로 만들어 일정에 배치했다 (최종 충족 상태는 부록 B).

10.1 타임라인

날짜	한 일	주요 산출물
10/27 (화)	EDA, 라벨 정제 A~C, 조합 단위 5-Fold, 파이프라인 모듈화·테스트, 베이스라인과 E1~E3 탐색, 분류기 3종·2단계, WBF 직접 구현, 11s·11m 5-Fold, 최종 모델·제출 후보	`01_eda`, `02_preprocess`, `03_baseline`, `src/pilldet`, 제출 후보 3종
10/28 (수)	리뷰 반영(근사 메타 검증, 에포크 민감도, OOF 완전성·설정 스냅샷 검사), CLAHE 5-Fold 비교, 보고서 구성안	`wbf_meta_validation.csv`, `compare_oof.py`
10/29 (목)	보고서 초안과 리뷰 반영, 결과 분석(클래스별 AP · 실패 유형 · 처음 보는 약과 신뢰도), 실패 유형 1:1 매칭으로 재작성	`error_analysis.py`, 보고서 초안
10/30 (금)	원본 라벨 오류 4장 발견·수정(감사 D·E) → 5-Fold·최종 모델 전체 재학습, CLAHE 재검증, 학습률(R11)·TTA(R14) 실험, 데모 앱, 보고서 완성	`audit_labels.py`, `label_review.csv`, 데모 앱, 보고서
11/02 주	대회 지표 · 제출 형식 확인과 재평가, 시연 영상, GitHub 반영, 저장소 · 보고서(11/05 19:00), 업무일지 · Kaggle(11/06 23:50)	Kaggle 점수 (주력 0.413), 시연 영상

표 10-1. 계획(`docs/PLAN.md`)과 비교하면 실험은 계획보다 이틀 앞섰고, 오류 분석에서 찾은 라벨 오류 때문에 10/30에 전체 재학습이 추가됐다.

10.2 검토 반영 이력

단계마다(설계 → 중간 결과 → 완성본) 외부 리뷰를 받고, 지적을 그대로 받아들이지 않고 코드·데이터로 다시 확인한 뒤 고쳤다. 결론을 바꾼 주요 사례:

지적 · 발견	확인	조치
WBF 설정을 같은 OOF에서 골라 최댓값을 보고	선택 편향이 맞다	근사 메타 검증 추가, 한계("완전 격리 아님") 명시
"37종 OOF가 Kaggle 점수에 가깝다"	희귀 19종을 뺀 값이라 과장	"조건부 진단값"으로 용어 통일
OOF 집계가 파일 존재만 확인	누락·중복 행도 통과했다	완전성 검사로 멈추게 하고 테스트 추가
"모든 조합을 세 각도로 촬영"	조합당 1~3장이었다	README·보고서 정정
"모르는 약은 신뢰도로 거부"	0.96 오답 사례와 모순	신뢰도 단독 불충분, 운영 임계값 미제시로 정정
실패 유형 집계가 예측을 여러 정답에 재사용	맞다 (4건 차이)	점수 순 1:1 매칭 + 회귀 테스트
그 4건을 추적하다 **원본 라벨 오류 4장** 발견	다른 각도 사진과 대조해 확정	감사 D·E 추가, 라벨 수정, **전체 재학습**, "학습한 약끼리 고신뢰 오분류" 결론 철회
CLAHE 차이(−0.0015)가 결론 여유보다 작음	재학습 뒤 다시 확인 필요	수정 라벨로 5-Fold 재검증 → 같은 결론 (6.5절)

표 10-2. 전체 이력은 날짜별 업무일지와 Git 커밋 메시지에 있다.

10.3 발표 참여

개인 사정으로 팀 프로젝트에서 개인 프로젝트로 전환되어 별도 발표 순서는 없다. 발표일에는 출석해 다른 팀 발표를 듣는다. 대신 (1) 데모 앱 시연 영상(`docs/demo/demo.mp4`, README에 링크), (2) 주강사와의 1:1 진행 공유를 발표 참여의 근거로 남긴다.

11. 비즈니스 시사점과 한계

11.1 서비스에 주는 시사점

- **여러 조합에서 반복 관측된 약은 높은 진단값을 보였다.** 37종 조건부 OOF 0.950(대리지표)은 37종 전체를 합친 값이며, 모든 약의 정확도를 보장하지 않는다 (하위 약 AP50-95 0.64, 8.1절). 서비스 범위를 정하려면 약별 AP와 실패 사례(8장)를 함께 봐야 한다.
- **처음 보는 약을 다른 약으로 확신하는 것이 가장 큰 위험이다.** 현재 최종 후보와 같은 구성의 OOF에서 처음 보는 약 63박스의 24%가 신뢰도 0.9 이상으로 다른 약 이름을 받았다 (8.5절, 신뢰도로 가르는 AUROC 0.88, 같은 촬영 환경의 OOF 기준). 따라서 **신뢰도 임계값만으로는 "모르는 약"을 걸러낼 수 없다.** 병용 금기 안내처럼 틀린 이름이 위험으로 이어지는 기능에는 (1) 학습에 없는 약으로 따로 만든 검증 세트에서 거부율과 임계값을 보정하고, (2) 약 이름·각인을 사용자가 확인하는 단계를 필수로 두어야 한다. 현재 데이터에는 독립된 "모르는 약" 검증 세트가 없어, 이 보고서는 운영 임계값을 제시하지 않는다.
- **모델 교체보다 데이터 확보가 먼저일 수 있다.** 이번에 시험한 해상도·구조·분류기 범위에서는 처음 보는 약 문제가 개선되지 않았다. 희귀 약의 사진을 더 모으는 것이 가장 직접적인 방법으로 보이지만, 이 프로젝트에서 효과를 측정하지는 않았다.

11.2 한계

- 한 fold에만 있는 희귀 19종의 실제 성능은 이 검증으로 잴 수 없다.
- 단색 배경·고정 촬영 환경의 데이터다. 사용자가 손으로 찍은 사진(조명, 배경, 각도)에서는 성능이 낮아질 수 있다.
- 근사 메타 검증은 완전히 격리된 추정이 아니며, 최종 에포크는 휴리스틱이다.
- 일부 5-Fold 산출물은 pandas · Pillow 버전이 다른 환경에서 만들어졌을 수 있다 (9.2절).
- 라벨 감사 E는 모델 예측으로 후보를 만들었으므로, 모델이 같이 틀린 라벨 오류는 찾지 못한다. 남은 라벨 오류의 수는 알 수 없다.

12. 회고와 향후 과제

12.1 잘한 점

- **재는 법을 먼저 만들었다.** 조합 단위 분할과 open-set 상한 분해 덕분에 0.63이라는 낮은 OOF를 "모델이 나빠서"가 아니라 "분할 구조 때문"으로 설명할 수 있었고, 모델 비교를 같은 조건(37종 조건부)에서 했다.
- **음성 결과를 버리지 않았다.** 고해상도·YOLO26·Copy-Paste·2단계·CLAHE·학습률·TTA의 기각 근거를 수치로 남겨, 같은 시도를 반복하지 않게 했다. 학습률은 판단 규칙을 실행 전에 적어 두어, 결과를 본 뒤 기준을 바꾸지 않았다.
- **숫자가 왜 바뀌었는지 끝까지 따라갔다.** 실패 유형 집계를 1:1 매칭으로 바꾸자 달라진 4건을 추적해, 정제가 놓친 원본 라벨 오류를 찾고 전체를 다시 학습했다.

12.2 아쉬운 점

- **처음 무결성 검사의 범위를 좁게 잡았다.** "같은 약 중복"만 보고 "다른 약끼리 같은 좌표"를 놓쳤다. 검사 항목을 "가능한 라벨 오류 유형" 목록에서 출발해 정했어야 했다.
- **fold 0 하나로 탐색한 실험이 많다.** 시간 때문에 E1~E3는 fold 0(독립 조합 23개)으로만 비교했고, 그 결과는 라벨 수정 전 기록이다.
- **희귀 19종의 성능은 끝내 잴 수 없었다.** 데이터 구조상 한계지만, 서비스 관점에서는 가장 중요한 질문이다.

12.3 향후 과제

- **"모르는 약" 검증 세트**: 학습에 없는 약 사진을 따로 모아 거부율·임계값을 보정한다. 지금은 운영 임계값을 제시할 근거가 없다.
- **닮은 약의 혼동**: 색·모양이 같고 각인만 다른 약을 각인 영역 중심으로 비교하는 방법을 검증한다.
- **실사용 사진**: 단색 배경·고정 촬영이 아닌 사진(조명·배경·각도)에서 성능 저하를 측정한다.
- **라벨 감사 자동화**: 같은 조합의 다른 각도 사진 사이에서 라벨 일관성을 검사하는 규칙을 만들어, 모델 예측에 기대지 않고 라벨 교환을 찾는다.

부록 A. 56종 클래스별 AP (5-Fold OOF)

현재 최종 후보와 같은 구성(WBF 2:1, IoU 0.6)의 OOF. "19종"은 한 fold에만 있어 검증될 때 항상 학습에 없는 약이다. "학습 박스"는 그 약이 검증될 때 나머지 fold에 있던 같은 약 박스 수의 평균. 출처: reports/experiments/error_per_class.csv

약 이름	코드	그룹	AP50-95	AP50	정답	조합	학습 박스
노바스크정 5mg	19861	37종	1.000	1.000	6	2	3.0
리바로정 4mg	29667	37종	1.000	1.000	18	9	8.6
리피로우정 20mg	22074	37종	1.000	1.000	16	9	11.9
리피토정 20mg	16232	37종	1.000	1.000	21	11	15.3
무코스타정(레바미피드)(비매품)	3544	37종	1.000	1.000	6	2	3.0
스토가정 10mg	19607	37종	1.000	1.000	6	2	3.0
아질렉트정(라사길린메실산염)	31863	37종	1.000	1.000	12	9	9.5
엑스포지정 5/160mg	20877	37종	1.000	1.000	12	4	7.5
종근당글리아티린연질캡슐(콜린알포세레이트)	18357	37종	1.000	1.000	13	9	10.3
큐시드정 31.5mg/PTP	25438	37종	1.000	1.000	6	2	3.0
크레스토정 20mg	16262	37종	1.000	1.000	23	11	17.2
트라젠타정(리나글립틴)	28763	37종	1.000	1.000	9	3	6.0
기넥신에프정(은행엽엑스)(수출용)	3483	37종	0.997	1.000	45	15	35.6
일양하이트린정 2mg	3351	37종	0.996	1.000	157	89	125.5
로수바미브정 10/20mg	38162	37종	0.993	1.000	18	10	13.7
에빅사정(메만틴염산염)(비매품)	13900	37종	0.993	1.000	15	7	12.0
자누메트정 50/850mg	25367	37종	0.993	0.993	12	4	9.0
카발린캡슐 25mg	41768	37종	0.993	1.000	16	9	12.6
뉴로메드정(옥시라세탐)	3832	37종	0.992	0.992	20	10	14.7
리리카캡슐 150mg	18147	37종	0.992	1.000	15	9	11.6
마도파정	20014	37종	0.992	1.000	17	9	13.3
글리아타민연질캡슐	32310	37종	0.988	1.000	15	9	11.9
플라빅스정 75mg	20238	37종	0.988	1.000	20	11	15.7
트윈스타정 40/5mg	27733	37종	0.986	1.000	12	4	4.5
자누비아정 50mg	22347	37종	0.978	0.978	9	3	6.0
글리틴정(콜린알포세레이트)	33880	37종	0.972	1.000	17	9	13.1
가바토파정 100mg	16548	37종	0.967	1.000	18	6	13.0
오마코연질캡슐(오메가-3-산에틸에스테르90)	16688	37종	0.967	1.000	8	7	6.2
아모잘탄정 5/100mg	25469	37종	0.966	0.978	12	4	4.5
로수젯정10/5밀리그램	36637	37종	0.963	0.977	19	10	13.6
아토젯정 10/40mg	35206	37종	0.935	0.942	37	16	28.9
뮤테란캡슐 100mg	2483	37종	0.928	1.000	9	3	4.0
콜리네이트연질캡슐 400mg	19232	37종	0.920	1.000	17	9	13.3
아토르바정 10mg	21325	37종	0.884	0.901	22	10	16.9
에어탈정(아세클로페낙)	4543	37종	0.883	1.000	6	2	3.0
보령부스파정 5mg	1900	37종	0.750	0.775	15	5	8.4
트라젠타듀오정 2.5/850mg	30308	37종	0.636	0.636	9	3	4.0

약 이름	코드	그룹	AP50-95	AP50	정답	조합	학습 박스
동아가바펜틴정 800mg	16551	19종	0.100	0.200	3	1	0.0
놀텍정 10mg	24850	19종	0.000	0.000	3	1	0.0
다보타민큐정 10mg/병	12778	19종	0.000	0.000	6	2	0.0
라비에트정 20mg	21771	19종	0.000	0.000	3	1	0.0
레일라정	29451	19종	0.000	0.000	3	1	0.0
리렉스펜정 300mg/PTP	12081	19종	0.000	0.000	3	1	0.0
맥시부펜이알정 300mg	22362	19종	0.000	0.000	3	1	0.0
비모보정 500/20mg	29345	19종	0.000	0.000	6	2	0.0
신바로정	33009	19종	0.000	0.000	3	1	0.0
써스펜8시간이알서방정 650mg	13395	19종	0.000	0.000	3	1	0.0
아빌리파이정 10mg	12247	19종	0.000	0.000	3	1	0.0
알드린정	3743	19종	0.000	0.000	3	1	0.0
에스원엠프정 20mg	33208	19종	0.000	0.000	3	1	0.0
울트라셋이알서방정	27926	19종	0.000	0.000	3	1	0.0
자누메트엑스알서방정 100/1000mg	31885	19종	0.000	0.000	3	1	0.0
제미메트서방정 50/1000mg	34597	19종	0.000	0.000	3	1	0.0
졸로푸트정 100mg	27993	19종	0.000	0.000	3	1	0.0
카나브정 60mg	27777	19종	0.000	0.000	3	1	0.0
트루비타정 60mg/병	19552	19종	0.000	0.000	3	1	0.0

부록 B. 요구사항 충족 (R1~R17)

#	요구사항	충족 근거	상태
R1	요구사항 분석·타임라인	`docs/PLAN.md` 추적표·일정 (10.1절)	완료
R2	업무일지	`docs/worklog/` 10/27~11/05	진행
R3	개발 환경·GitHub·구조	레포, `requirements.txt`, 모듈 구조 (9장). 최종 반영은 11/02 주	완료
R4	EDA	발견 6개 → 결정 (2장)	완료
R5	파일 구조·메타데이터 확인	파일명 ↔ 라벨 대조, 무결성 검사, 라벨 감사 A~E, 라벨 오류 15건 수정 (보고서 3장)	완료
R6	전처리	해상도 640/960/1280 (6.1절), CLAHE 5-Fold 전후 비교 (6.5절)	완료
R7	데이터 증강	상하 뒤집기·밝기·Copy-Paste 전후 비교 (6.1·6.4절)	완료
R8	파이프라인 자동화	`src/pilldet` 17개 모듈, 스크립트, 테스트 함수 40개 (9장)	완료
R9	VGG·ResNet·YOLO 등 모델	YOLO11n·s·m·YOLO26s, VGG16·ResNet50·EfficientNet-B0 (6.1·6.3절)	완료
R10	성능 지표 비교	검출 mAP50/50-95, 분류 정확도·정밀도·재현율·F1·log loss (6장)	완료
R11	하이퍼파라미터 튜닝	학습률 3수준, 해상도, 모델 크기, 에포크 민감도 (6.7·7.1절). 배치 크기는 미실험	완료
R12	인식 결과 시각화	정답 vs 예측, 실패 사례, 테스트 예측 (5.3·8장)	완료
R13	추가 전처리·외부 데이터	금지 데이터 2종 미사용 확인. 허용된 추가 AI Hub 데이터와 테스트 의사 라벨은 쓰지 않았다	부분
R14	기타 성능 개선 기법	WBF 직접 구현·근사 메타 검증, 5-Fold, TTA (6.6·6.7절)	완료
R15	분석 보고서	이 보고서	완료
R16	시연 영상	데모 앱 `app/demo.py`, 영상 `docs/demo/demo.mp4` (실행 화면 캡처 + 자막, 음성 없음). 업로드 기능은 앱에 있으나 영상에서는 테스트 이미지 선택만 보여 준다	부분
R17	Kaggle 제출	후보 4종 제출 완료, 주력 public 0.41349 (7.2절)	완료

표 B-1. 상태는 2026-11-05 기준.

참고문헌

1. G. Jocher, J. Qiu. *Ultralytics YOLO11*, 2024. github.com/ultralytics/ultralytics
2. T.-Y. Lin et al. Microsoft COCO: Common Objects in Context. *ECCV*, 2014. doi:10.1007/978-3-319-10602-1_48
3. COCO API (pycocotools). github.com/cocodataset/cocoapi
4. R. Solovyev, W. Wang, T. Gabruseva. Weighted boxes fusion: Ensembling boxes from different object detection models. *Image and Vision Computing* 107, 2021. doi:10.1016/j.imavis.2021.104117
5. K. Zuiderveld. Contrast Limited Adaptive Histogram Equalization. *Graphics Gems IV*, Academic Press, 1994. doi:10.1016/B978-0-12-336156-1.50061-6
6. G. Ghiasi et al. Simple Copy-Paste is a Strong Data Augmentation Method for Instance Segmentation. *CVPR*, 2021. arXiv:2012.07177
7. K. Simonyan, A. Zisserman. Very Deep Convolutional Networks for Large-Scale Image Recognition. *ICLR*, 2015. arXiv:1409.1556
8. K. He, X. Zhang, S. Ren, J. Sun. Deep Residual Learning for Image Recognition. *CVPR*, 2016. doi:10.1109/CVPR.2016.90
9. M. Tan, Q. V. Le. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. *ICML*, 2019. arXiv:1905.11946
10. F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *JMLR* 12, 2011. (StratifiedGroupKFold) jmlr.org/papers/v12/pedregosa11a
11. B. Efron, R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993. doi:10.1007/978-1-4899-4541-9
12. AI Hub. 경구약제 이미지 데이터. 한국지능정보사회진흥원. www.aihub.or.kr (대회 규칙에 따라 원본 조합 데이터는 사용하지 않음)